


## 08-03 HMM 隐马尔可夫模型

# 真核基因组基因识别

- 真核基因识别较之原核基因识别要困难的多
  - ▣ 内含子
  - ▣ 调控因子
- HMM

# HMM 实例



盒子	1	2	3	4
红球R	5	3	6	8
白球W	5	7	4	2

- 假设有**4**个盒子，每个盒子都有红白两种颜色的球。
- 按照如下规则取球：
- 从四个盒子中等概率取一个盒子；从跟这个盒子里随机抽取一个球。记录颜色并放回。
- 从当前盒子，随机转移到另外一个盒子。转移矩阵如下，

	盒1	盒2	盒3	盒4
盒1	0	1	0	0
盒2	0.4	0	0.6	0
盒3	0	0.4	0	0.6
盒4	0	0	0.5	0.5

- 确定转移的盒子之后，从中随机抽取**1**个球，记录颜色并放回。
- 如此重复**5**次。得到观测序列  $O = \{R, W, R, W, R\}$

- 在这个过程中观察者只能观测到球的颜色，而观测不到盒子的序列。
- 在这个过程中，有两个随机序列：
  - ▣ 盒子的序列（状态序列）；隐藏的；
  - ▣ 球颜色的序列（观测序列）；可观测的。
- 这就是一个HMM的例子。

# HMM实例——约束


在上述实验中，有几个要点需要注意：

- **不能被直接观察盒子之间的转移**
- **从盒子中所选取的球的颜色和盒子并不是一一对应的**
- **每次选取哪个盒子由一组转移概率决定**

# HMM概念

- HMM的**状态（盒子）**是不确定或不可见的，只有通过**观测序列（球的颜色）**的随机过程才能表现出来
- 观察到的事件与状态并不是一一对应，而是通过一组概率分布相联系
- HMM是一个双重随机过程，两个组成部分：
  - ▣ **马尔可夫链**：描述**状态**的转移，用**转移概率**描述。
  - ▣ **一般随机过程**：描述状态与观察序列间的关系，用**观察值概率**描述。

# HMM组成



## HMM的组成示意图

盒1, 盒2,  
盒3, 盒4,

R, R,W,W,R



- 观测序列： $O = \{\text{红}, \text{白}, \text{红}\}$
- 状态集合（盒子对应状态）： $Q = \{\text{盒1}, \text{盒2}, \text{盒3}, \text{盒4}\}, N = 4$
- 观测集合（球的颜色）： $V = \{\text{红}, \text{白}\}, M = 2$
- 状态序列和观测序列长度  $T = 5$ .
- 初始概率分布  $\pi = (0.25, 0.25, 0.25, 0.25)^T$

- 状态转移矩阵： $A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0.4 & 0 & 0.6 & 0 \\ 0 & 0.4 & 0 & 0.6 \\ 0 & 0 & 0.5 & 0.5 \end{bmatrix}_{N \times N}$

- 观测概率分布  $B = \begin{bmatrix} 0.5 & 0.5 \\ 0.3 & 0.7 \\ 0.6 & 0.4 \\ 0.8 & 0.2 \end{bmatrix}_{N \times M}$

HMM的基本要素

设观测序列 $O = (o_1, o_2, \dots, o_T)$ , 对应的状态序列 $Q = (q_1, q_2, \dots, q_T)$

参数	含义	实例	
N	状态数目	盒子的数目	$S = (S_1, S_2, \dots, S_N)$
M	每个状态可能的观察值数目	彩球颜色数目	$V = (v_1, v_2, \dots, v_M)$
A	与时间无关的状态转移概率矩阵	在选定某个盒子的情况下, 选择另一个盒的概率	$A = [a_{ij}]_{N \times N}$ $a_{ij} = P(q_{t+1} = S_j   q_t = S_i)$
B	给定状态下, 观察值概率分布	每个盒中的颜色分布	$B = [b_j(k)]_{N \times M}$ $b_j(k) = P(o_t = v_k   q_t = S_j),$ $1 \leq j \leq N, 1 \leq k \leq M$
$\pi$	初始状态空间的概率分布	初始时选择某盒的概率	$\pi = (\pi_1, \dots, \pi_N)$

□ 模型可用五元组  $\lambda = (N, M, \pi, A, B)$  或三元组  $\lambda = (\pi, A, B)$  来描述HMM。

# HMM的两个假设

设观测序列 $O = (o_1, o_2, \dots, o_T)$ , 对应的状态序列 $Q = (q_1, q_2, \dots, q_T)$

- 假设隐藏的**Markov**链在任意时刻 $t$ 状态，只依赖前一时刻的状态，和其他时刻的状态和观测序列无关，和 $t$ 也无关。（齐次Markov性）
  - ▣  $P(q_t | q_{t-1}, o_{t-1}, \dots, q_1, o_1) = P(q_t | q_{t-1})$
- 假设任意时刻的观测只依赖于该时刻的Markov链的状态，与其他观测和状态无关。（观测独立性）
  - ▣  $P(o_t | q_T, o_T, q_{T-1}, o_{T-1}, \dots, q_{t+1}, o_{t+1}, q_{t-1}, o_{t-1}, \dots, q_1, o_1) = P(o_t | q_t)$

## □ 算法1：生成观测序列

□ 输入：HMM模型参数 $\lambda = (A, B, \pi)$ , 观测序列长度 $T$

□ 输出：观察序列 $O = (o_1, o_2, \dots, o_T)$

1. 按照初始状态分布 $\pi$ 产生状态 $S_i$
2. 令 $t = 1$
3. 按照状态 $q_t$ 的观测概率分布 $b_{q_t}(k)$ 生成 $o_t$
4. 按照状态 $q_t$ 的状态转移概率 $a_{q_t, q_{t+1}}$ 产生状态 $q_{t+1}$ ,
5. 令 $t = t + 1$ , 如果 $t < T$ , 转3. 否则终止。

# HMM的三个基本问题

- 问题1：概率计算问题（评估模型与观测序列之间匹配度）
  - ▣ 给定模型 $\lambda = (A, B, \pi)$ ，观察序列 $O = (o_1, o_2, \dots, o_T)$ ，计算在模型 $\lambda$ 下观测序列 $O$ ，出现的概率 $P(O|\lambda)$ ？
- 问题2：学习问题：（如何训练模型能更好地描述观测数据）
  - ▣ 已知观测序列 $O = (o_1, o_2, \dots, o_T)$ ，估计模型 $\lambda = (A, B, \pi)$ 参数，使得在该参数下，观测序列概率 $P(O|\lambda)$ 最大。即，用极大似然估计方法估计参数。
- 问题3：预测问题或解码问题：（根据观测序列推断隐藏的状态序列）
  - ▣ 已知模型 $\lambda = (A, B, \pi)$ 和观测序列 $O = (o_1, o_2, \dots, o_T)$ ，求最有可能对应的状态序列 $Q = (q_1, q_2, \dots, q_T)$ 。即，在该状态序列下，观测序列的条件概率 $P(O|Q)$ 最大？

## 问题1： 概率计算问题：

给定模型  $\lambda = (A, B, \pi)$  ， 观察序列  $O = (o_1, o_2, \dots, o_T)$ ， 计算在模型  $\lambda$  下观测序列  $O$ ， 出现的概率  $P(O|\lambda)$ ？

# 问题1 概率计算

给定模型  $\lambda = (A, B, \pi)$ ，观察序列  $O = (o_1, o_2, \dots, o_T)$ ，计算在模型  $\lambda$  下观测序列  $O$ ，出现的概率  $P(O|\lambda)$ ？

- 法1：直接计算：列举所有可能的长度为  $T$  的状态序列，求各个状态序列  $Q$  和观测序列  $O$  的联合概率，然后对所有可能的状态序列求和。
- 给定一个固定的状态序列  $Q = (q_1, q_2, \dots, q_T)$ ，观测序列  $O = (o_1, o_2, \dots, o_T)$  的概率  $P(O|Q, \lambda) = \prod_{t=1}^T P(o_t|q_t, \lambda) = b_{q_1}(o_1)b_{q_2}(o_2) \cdots b_{q_T}(o_T)$

其中  $b_{q_t}(o_t)$  表示在  $q_t$  状态下观测到  $o_t$  的概率

- 状态序列  $Q$  的概率  $P(Q|\lambda) = \pi_{q_1} a_{q_1 q_2} \cdots a_{q_{T-1} q_T}$
- $O$  和  $Q$  同时出现的联合概率  $P(O, Q|\lambda) = P(O|Q, \lambda)P(Q|\lambda)$
- 对所有的状态序列  $Q$  求和，得到序列  $O$  的概率：

$$P(O|\lambda) = \sum_{all\ Q} P(O, Q|\lambda) = \sum_{all\ Q} P(O|Q, \lambda)P(Q|\lambda)$$

法1:直接计算不可取。

$$\begin{aligned} P(O|\lambda) &= \sum_{all\ Q} P(O, Q|\lambda) = \sum_{all\ Q} P(O|Q, \lambda)P(Q|\lambda) \\ &= \sum_{q_1, q_2, \dots, q_T} \pi_{q_1} b_{q_1}(o_1) a_{q_1 q_2} b_{q_2}(o_2) \dots a_{q_{T-1} q_T} b_{q_T}(o_T) \end{aligned}$$

约  $2T * N^T$  计算量。 若  $N=5$ ,  $T=100$ ,  $2 * 100 * 5^{100} \approx 10^{72}$



# 问题1：法2 前向法

□ 定义前向变量:  $\alpha_t(i)$  表示到时刻  $t$  部分观测序列为  $o_1, o_2, \dots, o_t$  且状态为  $q_t$  的概率。  
$$\alpha_t(i) = P(o_1, o_2, \dots, o_t, q_t = S_i | \lambda) \quad 1 \leq t \leq T$$

□ **算法2：前向法：**

□ 输入:  $\lambda, O$ ; 输出:  $P(O|\lambda)$

▣ 初始化:  $\alpha_1(i) = \pi_i b_i(o_1) \quad i = 1, 2, \dots, N$

▣ 递归: 
$$\alpha_{t+1}(j) = \left[ \sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(o_{t+1}) \quad t = 1, 2, \dots, T-1, 1 \leq j \leq N$$

▣ 终结: 
$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$



# 解决问题1 前向法

$b_{q_t}(\mathbf{o}_t)$ 表示在 $q_t$ 状态下观测到 $\mathbf{o}_t$ 的概率

$$\begin{aligned}\alpha_{t+1}(\mathbf{j}) &= P(\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_t, \mathbf{o}_{t+1}, \mathbf{q}_{t+1} = \mathbf{s}_j | \lambda) \\&= \sum_{i=1}^N P(\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_t, \mathbf{q}_t = \mathbf{s}_i, \mathbf{o}_{t+1}, \mathbf{q}_{t+1} = \mathbf{s}_j | \lambda) \\&= \sum_{i=1}^N P(\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_t, \mathbf{q}_t = \mathbf{s}_i | \lambda) * P(\mathbf{o}_{t+1}, \mathbf{q}_{t+1} = \mathbf{s}_j | \mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_t, \mathbf{q}_t = \mathbf{s}_i, \lambda) \\&= \sum_{i=1}^N P(\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_t, \mathbf{q}_t = \mathbf{s}_i | \lambda) * P(\mathbf{o}_{t+1}, \mathbf{q}_{t+1} = \mathbf{s}_j | \mathbf{q}_t = \mathbf{s}_i, \lambda) \\&= \sum_i P(\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_t, \mathbf{q}_t = \mathbf{s}_i | \lambda) * P(\mathbf{q}_{t+1} = \mathbf{s}_j | \mathbf{q}_t = \mathbf{s}_i, \lambda) * P(\mathbf{o}_{t+1} | \mathbf{q}_{t+1} = \mathbf{s}_j, \mathbf{q}_t = \mathbf{s}_i, \lambda) \\&= \left[ \sum_i^N \alpha_t(i) a_{ij} \right] b_j(\mathbf{o}_{t+1})\end{aligned}$$

灰色部分，表示可省略，即 $P(\mathbf{o}_{t+1} | \mathbf{q}_{t+1} = \mathbf{s}_j, \mathbf{q}_t = \mathbf{s}_i, \lambda) = P(\mathbf{o}_{t+1} | \mathbf{q}_{t+1} = \mathbf{s}_j, \lambda)$

# 前向法示意图



计算  $\alpha_t(j), t = 1, 2, \dots, T, j = 1, \dots, N$ , 计算量  $NNT + N \sim O(TN^2)$ 。  $N=5$ ,  $M=100$ ,  $\Rightarrow$  计算量 3000

**例 10.2** 考虑盒子和球模型  $\lambda = (A, B, \pi)$ , 状态集合  $Q = \{1, 2, 3\}$ , 观测集合  $V = \{\text{红}, \text{白}\}$ ,

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$


设  $T = 3$ ,  $O = (\text{红}, \text{白}, \text{红})$ , 试用前向算法计算  $P(O | \lambda)$ .

(1) 计算初值

$$\alpha_1(1) = \pi_1 b_1(o_1) = 0.10$$

$$\alpha_1(2) = \pi_2 b_2(o_1) = 0.16$$

$$\alpha_1(3) = \pi_3 b_3(o_1) = 0.28$$



**例 10.2** 考虑盒子和球模型  $\lambda = (A, B, \pi)$ , 状态集合  $Q = \{1, 2, 3\}$ , 观测集合  $V = \{\text{红}, \text{白}\}$ ,

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$

设  $T=3$ ,  $O = (\text{红}, \text{白}, \text{红})$ , 试用前向算法计算  $P(O|\lambda)$ .

(2) 递推计算

$$\alpha_2(1) = \left[ \sum_{i=1}^3 \alpha_1(i) a_{i1} \right] b_1(o_2) = 0.154 \times 0.5 = 0.077$$


$$\alpha_2(2) = \left[ \sum_{i=1}^3 \alpha_1(i) a_{i2} \right] b_2(o_2) = 0.184 \times 0.6 = 0.1104$$

$$\alpha_2(3) = \left[ \sum_{i=1}^3 \alpha_1(i) a_{i3} \right] b_3(o_2) = 0.202 \times 0.3 = 0.0606$$

$$\alpha_3(1) = \left[ \sum_{i=1}^3 \alpha_2(i) a_{i1} \right] b_1(o_3) = 0.04187$$

$$\alpha_3(2) = \left[ \sum_{i=1}^3 \alpha_2(i) a_{i2} \right] b_2(o_3) = 0.03551$$

$$\alpha_3(3) = \left[ \sum_{i=1}^3 \alpha_2(i) a_{i3} \right] b_3(o_3) = 0.05284$$



**例 10.2** 考虑盒子和球模型  $\lambda = (A, B, \pi)$ , 状态集合  $Q = \{1, 2, 3\}$ , 观测集合  $V = \{\text{红}, \text{白}\}$ ,

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$

设  $T = 3$ ,  $O = (\text{红}, \text{白}, \text{红})$ , 试用前向算法计算  $P(O | \lambda)$ .

(3) 终止

$$P(O | \lambda) = \sum_{i=1}^3 \alpha_3(i) = 0.13022$$

# 问题1：法3 后向法

□ 与前向法类似，定义后向变量 $\beta_t(i)$ 表示从 $t+1$ 时刻到结束，在时间 $t$ 时刻，给定状态 $S_i$ ，部分观测序列的概率。

□ **算法3：向后算法：**  $\beta_t(i) = P(\mathbf{o}_{t+1}, \mathbf{o}_{t+2}, \dots, \mathbf{o}_T | \lambda, q_t = S_i) \quad 1 \leq t \leq T-1$

□ 输入： $\lambda, O$ ；输出： $P(O|\lambda)$

▣ 初始化：

$$\beta_T(i) = 1 \quad i = 1, 2, \dots, N$$

▣ 递归：

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(\mathbf{o}_{t+1}) \beta_{t+1}(j), \quad t = T-1, T-2, \dots, 1, 1 \leq i \leq N$$

▣ 终结：


$$P(O|\lambda) = \sum_{i=1}^N \pi_i \beta_1(i) b_i(\mathbf{o}_1)$$

# 问题1 后向法

$$\beta_t(i) = P(\mathbf{o}_{t+1}, \mathbf{o}_{t+2}, \dots, \mathbf{o}_T | \lambda, q_t = S_i)$$
$$\beta_{t+1}(j) = P(\mathbf{o}_{t+2}, \mathbf{o}_{t+3}, \dots, \mathbf{o}_T | \lambda, q_{t+1} = S_j)$$

$$\begin{aligned}\beta_t(i) &\stackrel{\text{def}}{=} P(\mathbf{o}_{t+1}, \mathbf{o}_{t+2}, \dots, \mathbf{o}_T | q_t = S_i, \lambda) \\&= \sum_{j=1}^N P(\mathbf{o}_{t+1}, \mathbf{o}_{t+2}, \dots, \mathbf{o}_T, \mathbf{q}_{t+1} = S_j | q_t = S_i, \lambda) \\&= \sum_j^N P(q_{t+1} = S_j | q_t = S_i, \lambda) * P(\mathbf{o}_{t+1}, \mathbf{o}_{t+2}, \dots, \mathbf{o}_T | \mathbf{q}_{t+1} = S_j, q_t = S_i, \lambda) \\&= \sum_j^N a_{ij} * P(\mathbf{o}_{t+1}, \mathbf{o}_{t+2}, \dots, \mathbf{o}_T | \mathbf{q}_{t+1} = S_j, \lambda) \\&= \sum_j^N a_{ij} * P(\mathbf{o}_{t+1} | \mathbf{q}_{t+1} = S_j, \lambda) * P(\mathbf{o}_{t+2}, \dots, \mathbf{o}_T | \mathbf{o}_{t+1}, \mathbf{q}_{t+1} = S_j, \lambda) \\&= \sum_j a_{ij} b_j(\mathbf{o}_{t+1}) \beta_{t+1}(j)\end{aligned}$$





# 前向后向算法

$$\begin{aligned} P(O|\lambda) &= \sum_{i=1}^N P(o_1, \dots, o_T, q_t = S_i | \lambda) \\ &= \sum_{i=1}^N P(o_1, \dots, o_t, q_t = S_i, o_{t+1}, \dots, o_T | \lambda) = \\ &\quad \sum_{i=1}^N P(o_1, \dots, o_t, q_t = S_i | \lambda) P(o_{t+1}, \dots, o_T | o_1, \dots, o_t, q_t = S_i, \lambda) = \\ &\quad \sum_{i=1}^N P(o_1, \dots, o_t, q_t = S_i | \lambda) P(o_{t+1}, \dots, o_T | q_t = S_i, \lambda) = \sum_{i=1}^N \alpha_t(i) \beta_t(i) \end{aligned}$$

### 问题3： 预测问题或解码问题：

已知模型  $\lambda = (A, B, \pi)$  和观测序列  $O = (o_1, o_2, \dots, o_T)$ ，求最有可能对应的状态序列  $Q = (q_1, q_2, \dots, q_T)$ 。即，在该状态序列下，观测序列的条件概率  $P(O|Q)$  最大？

### 问题3: Viterbi算法(动态规划)

□目的：给定观察序列  $O = (o_1, \dots, o_T)$  找到最合适的单状态序列  $Q = (q_1, \dots, q_T)$ ，使得  $Q$  能够最为合理的解释观察序列  $O$ 。

□首先定义目标函数：

$$\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P[q_1 q_2 \dots q_{t-1}, q_t = S_i, o_1, o_2, \dots, o_t | \lambda]$$

即， $\delta_t(i)$  是在  $t$  时刻，状态为  $S_i$ ，所有单个路径中概率最大值。


通过递归可定义：

$$\begin{aligned} \delta_{t+1}(j) &= \max_{q_1, q_2, \dots, q_{t-1}} P[q_1 q_2 \dots q_{t-1}, q_t, q_{t+1} = S_j, o_1, o_2, \dots, o_t, o_{t+1} | \lambda] \\ &= \left[ \max_i \delta_t(i) a_{ij} \right] b_j(o_{t+1}) \end{aligned}$$

我们需要保存上述状态路径，定义

$$\psi_t(j) = \operatorname{argmax}_i [\delta_{t-1}(i) a_{ij}]$$

# Viterbi算法(续)



## 算法4: Viterbi算法

□ 输入：模型 $\lambda$ ，观测 $O$ ；输出最有路径 $Q = (q_1^*, \dots, q_T^*)$

□ 初始化：

$$\begin{aligned}\delta_1(i) &= \pi_i b_i(\mathbf{o}_1), & 1 \leq i \leq N \\ \psi_1(i) &= 0, & 1 \leq i \leq N\end{aligned}$$

□ 递归：

$$\begin{aligned}\delta_t(j) &= \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(\mathbf{o}_t), & 2 \leq t \leq T, 1 \leq j \leq N \\ \psi_t(j) &= \operatorname{argmax}_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}], & 2 \leq t \leq T, 1 \leq j \leq N\end{aligned}$$

□ 终结：

$$\begin{aligned}P^* &= \max_{1 \leq i \leq N} [\delta_T(i)] \\ q_T^* &= \operatorname{argmax}_{1 \leq i \leq N} [\delta_T(i)]\end{aligned}$$

□ 状态序列回溯：

$$q_t^* = \psi_{t+1}(q_{t+1}^*), \quad t = T-1, T-2, \dots, 1$$

例 10.3 例 10.2 的模型  $\lambda = (A, B, \pi)$ ,

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$

已知观测序列  $O = (\text{红}, \text{白}, \text{红})$ , 试求最优状态序列, 即最优路径  $I^* = (i_1^*, i_2^*, i_3^*)$ .

解 如图 10.4 所示, 要在所有可能的路径中选择一条最优路径, 按照以下步骤处理:

(1) 初始化. 在  $t=1$  时, 对每一个状态  $i$ ,  $i=1, 2, 3$ , 求状态为  $i$  观测  $o_1$  为红的概率, 记此概率为  $\delta_1(i)$ , 则

$$\delta_1(i) = \pi_i b_i(o_1) = \pi_i b_i(\text{红}), \quad i=1, 2, 3$$

代入实际数据

$$0.2 * 0.5$$

$$0.4 * 0.4$$

$$0.4 * 0.7$$


$$\delta_1(1) = 0.10, \quad \delta_1(2) = 0.16, \quad \delta_1(3) = 0.28$$

记  $\psi_1(i) = 0, \quad i=1, 2, 3$ .


例 10.3 例 10.2 的模型  $\lambda = (A, B, \pi)$ ,

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$


已知观测序列  $O = (\text{红}, \text{白}, \text{红})$ , 试求最优状态序列, 即最优路径  $I^* = (i_1^*, i_2^*, i_3^*)$ .



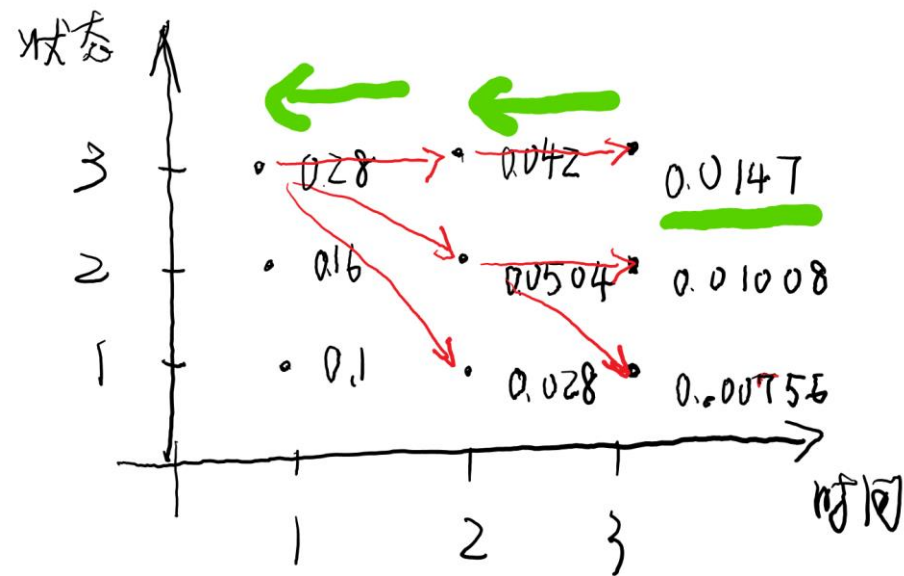


状态



状态







(2) 在  $t=2$  时, 对每个状态  $i$ ,  $i=1,2,3$ , 求在  $t=1$  时状态为  $j$  观测为红并在  $t=2$  时状态为  $i$  观测  $o_2$  为白的路径的最大概率, 记此最大概率为  $\delta_2(i)$ , 则

$$\delta_2(i) = \max_{1 \leq j \leq 3} [\delta_1(j) a_{ji}] b_i(o_2)$$

同时, 对每个状态  $i$ ,  $i=1,2,3$ , 记录概率最大路径的前一个状态  $j$ :

$$\psi_2(i) = \arg \max_{1 \leq j \leq 3} [\delta_1(j) a_{ji}], \quad i=1,2,3$$

计算:

$$\begin{aligned} \delta_2(1) &= \max_{1 \leq j \leq 3} [\delta_1(j) a_{j1}] b_1(o_2) \\ &= \max_j \{0.10 \times 0.5, 0.16 \times 0.3, 0.28 \times 0.2\} \times 0.5 \\ &= 0.028 \end{aligned}$$

$$\psi_2(1) = 3$$

$$\delta_2(2) = 0.0504, \quad \psi_2(2) = 3$$

$$\delta_2(3) = 0.042, \quad \psi_2(3) = 3$$

同样, 在  $t=3$  时,

$$\delta_3(i) = \max_{1 \leq j \leq 3} [\delta_2(j) a_{ji}] b_i(o_3)$$

$$\psi_3(i) = \arg \max_{1 \leq j \leq 3} [\delta_2(j) a_{ji}]$$

$$\delta_3(1) = 0.00756, \quad \psi_3(1) = 2$$

$$\delta_3(2) = 0.01008, \quad \psi_3(2) = 2$$

$$\delta_3(3) = 0.0147, \quad \psi_3(3) = 3$$




图 10.4 求最优路径

(3) 以  $P^*$  表示最优路径的概率, 则

$$P^* = \max_{1 \leq i \leq 3} \delta_3(i) = 0.0147$$

最优路径的终点是  $i_3^*$  :

$$i_3^* = \arg \max_i [\delta_3(i)] = 3$$

(4) 由最优路径的终点  $i_3^*$ , 逆向找到  $i_2^*, i_1^*$  :

$$\text{在 } t=2 \text{ 时, } i_2^* = \psi_3(i_3^*) = \psi_3(3) = 3$$

$$\text{在 } t=1 \text{ 时, } i_1^* = \psi_2(i_2^*) = \psi_2(3) = 3$$

于是求得最优路径, 即最优状态序列  $I^* = (i_1^*, i_2^*, i_3^*) = (3, 3, 3)$  .

## 解决问题2：学习问题(最困难)

已知观测序列  $O = (o_1, o_2, \dots, o_T)$ ，估计模型  $\lambda = (A, B, \pi)$  参数，使得在该参数下，观测序列概率  $P(O|\lambda)$  最大。即，用极大似然估计方法估计参数。




第一种情况，我们已知观测序列 $\mathbf{O}$ ，和状态序列(隐藏序列)  $\mathbf{S}$ 。

$$\mathbf{O}_1 = (o_1, \dots, o_T), \mathbf{S}_1 = (q_1, \dots, q_T)$$

# 引入两个变量 $\xi_t(i, j)$

- 定义 $\xi_t(i, j)$ 表示给定观测序列 $O$ ， $t$ 时刻状态为 $S_i$ ， $t + 1$ 时刻状态为 $S_j$ 的概率。
- $\xi_t(i, j) = P(q_t = S_i, q_{t+1} = S_j \mid O, \lambda)$



$$\begin{aligned}\xi_t(i, j) &= \frac{P(q_t = S_i, q_{t+1} = S_j, O \mid \lambda)}{P(O \mid \lambda)} \\ &= \frac{\alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}\end{aligned}$$

## 引入两个变量 $\gamma_t(i)$

$$\xi_t(i, j) = P(q_t = S_i, q_{t+1} = S_j \mid O, \lambda)$$

- 定义 $\gamma_t(i)$ 为给定观察序列 $O$ 和模型 $\lambda$ 之后，在时间 $t$ 时刻，状态为 $S_i$ 的概率。
- $\gamma_t(i) = P(q_t = S_i \mid O, \lambda) = \frac{P(O, q_t = S_i \mid \lambda)}{P(O \mid \lambda)} = \sum_{j=1}^N \xi_t(i, j)$
- $\gamma_t(i)$ 和前向概率，后向概率的关系
  - ▣  $\alpha_t(i)$ 在 $t$ 时刻，状态为 $S_i$ 的观测序列为 $o_1, \dots, o_t$ 的概率
  - ▣  $\beta_t(i)$ 在 $t$ 时刻，状态为 $S_i$ 的观测序列为 $o_{t+1}, \dots, o_T$ 的概率
  - ▣  $\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O \mid \lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{i=1}^N \alpha_t(i)\beta_t(i)}$

将 $\xi_t(i, j)$ ,  $\gamma_t(i)$  求和可得到有用的期望值。

- 在观测序列 $\mathbf{O}$ 下，状态 $\mathbf{S}_i$ 出现的期望数。  
□  $\sum_{t=1}^T \gamma_t(i)$
- 在观测序列 $\mathbf{O}$ 下，状态 $\mathbf{S}_i$ 转移的期望数。  
□  $\sum_{t=1}^{T-1} \gamma_t(i)$
- 在观测序列 $\mathbf{O}$ 下，状态 $\mathbf{S}_i$ 转移到 $\mathbf{S}_j$ 的期望数。  
□  $\sum_{t=1}^{T-1} \xi_t(i, j)$



## Baum-Welch算法

□ 基于以上定义，可以得到HMM的参数估计：

初始状态 $\pi_i$  的估计  $\hat{\pi}_i$  : 为样本中初始状态为 $S_i$  频率 (或  $t=1$ 时,  $\gamma_1(i)$  )

状态转移概率的估计  $\hat{a}_{ij} = \frac{\text{expected number of transitions from } S_i \text{ to } S_j}{\text{expected number of transitions from } S_i} =$

$\frac{\text{样本中时刻}t\text{处于状态}S_i, \text{时刻}t+1\text{转移到}S_j\text{的频数}A_{ij}}{\sum_{j=1, \dots, N} A_{ij}} =$

$$\frac{\sum_{t=1 \dots T-1} \xi_t(i, j)}{\sum_{t=1, \dots, T-1} \sum_{j=1, \dots, N} \xi_t(i, j)} = \frac{\sum_{t=1 \dots T-1} \xi_t(i, j)}{\sum_{t=1, \dots, T-1} \gamma_t(i)}$$

观测概率的估计  $\hat{b}_j(k) = \frac{\text{expected number of times in state } j \text{ and observing symbol } v_k}{\text{expected number of times in state } j}$

$$= \frac{\sum_{t=1, \dots, T, s.t. O_t=v_k} \gamma_t(j)}{\sum_{t=1, \dots, T} \gamma_t(j)}$$



第二种情况，只有观测序列 ○

# Baum-Welch 算法(EM算法原理)

- 给定HMM模型 $\lambda = (A, B, \pi)$ ，观测数据为 $O$ ，状态序列为 $Q$ ，那么HMM可看做一个含有隐变量 $Q$ 的概率模型。
- $P(O|\lambda) = \sum_t P(O|Q, \lambda)P(Q|\lambda)$
- 它的参数可以通过EM算法来求解。
  - ▣ EM算法E步：求联合分布 $P(O, Q|\lambda)$ 基于条件概率 $P(Q|O, \lambda')$ 的期望。其中 $\lambda'$ 是当前模型的参数。然后M步最大化这个期望，得到更新的模型参数 $\lambda$
  - ▣  $Q(\lambda, \lambda') = \sum_Q P(Q|O, \lambda') \log P(O, Q|\lambda)$ ，其中 $\lambda'$ 是HMM参数的当前估计。 $\lambda$ 要极大化HMM的参数。
  - ▣  $P(O, Q|\lambda) = \pi_{q_1} b_{q_1}(o_1) a_{q_1 q_2} b_{q_2}(o_2) \dots a_{q_{T-1} q_T} b_{q_T}(o_T)$

$$\square P(O, Q | \lambda) = \pi_{q_1} b_{q_1}(o_1) a_{q_1 q_2} b_{q_2}(o_2) \dots a_{q_{T-1} q_T} b_{q_T}(o_T)$$

$$\square Q(\lambda, \lambda') = \sum_Q P(Q|O, \lambda') \log P(O, Q|\lambda) = \sum_Q \frac{P(Q, O|\lambda')}{P(O|\lambda')} \log P(O, Q|\lambda) = \frac{\sum_Q P(Q, O|\lambda') \log P(O, Q|\lambda)}{P(O|\lambda')} \sim \sum_Q P(Q, O|\lambda') \log P(O, Q|\lambda)$$

□ 优化  $Q(\lambda, \lambda')$  等价优化  $\sum_Q P(Q, O|\lambda') \log P(O, Q|\lambda)$  (左式仍记为  $Q(\lambda, \lambda')$ )

$$\square Q(\lambda, \lambda') = \sum_Q \log \pi_{q_1} P(O, Q | \lambda') + \sum_Q \left( \sum_{t=1}^{T-1} \log a_{q_t q_{t+1}} \right) P(O, Q | \lambda') + \sum_Q \left( \sum_{t=1}^T \log b_{q_t}(o_t) \right) P(O, Q | \lambda')$$

□

$$\begin{aligned}
Q(\lambda, \lambda') &= \sum_Q \log \pi_{q_1} P(O, Q \mid \lambda') + \sum_Q \left( \sum_{t=1}^{T-1} \log a_{q_t q_{t+1}} \right) P(O, Q \mid \lambda') \\
&+ \sum_Q \left( \sum_{t=1}^T \log b_{q_t}(o_t) \right) P(O, Q \mid \lambda')
\end{aligned}$$

- **M**步，极大化**Q**函数，求模型参数 $\lambda$ 。由于参数单独出现在三项中  $(\pi, A, B)$ ，可分别求最大化。
- 第一项：  $\sum_Q \log \pi_{q_1} P(O, Q \mid \lambda') = \sum_{i=1, \dots, N} \log \pi_i P(O, q_1 = S_i \mid \lambda')$
- 拉格朗日函数

$$\frac{\partial}{\partial \pi_i} \left( \sum_{i=1}^N \log \pi_i P(O, q_1 = S_i \mid \lambda') + \gamma \left( \sum_{i=1}^N \pi_i - 1 \right) \right) = 0$$

$$\text{得 } \frac{1}{\pi_i} P(O, q_1 = S_i \mid \lambda') + \gamma = 0 \rightarrow P(O, q_1 = S_i \mid \lambda') + \pi_i \gamma = 0$$

$$\text{两边对 } i \text{ 求和 得 } \gamma = -P(O \mid \lambda') \rightarrow \pi_i = \frac{P(O, q_1 = S_i \mid \lambda')}{P(O \mid \lambda')}$$

$$\square \text{第二项: } \sum_Q \left( \sum_{t=1}^{T-1} \log a_{q_t q_{t+1}} \right) P(O, Q \mid \lambda') = \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \log a_{ij} P(O, q_t = S_i, q_{t+1} = S_j \mid \lambda')$$

□ 拉格朗日函数求导

$$\square \frac{\partial}{\partial a_{ij}} \left( \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \log a_{ij} P(O, q_t = S_i, q_{t+1} = S_j \mid \lambda') + \gamma (\sum_{j=1}^N a_{ij} - 1) \right) = 0$$

$$\square P(O, q_t = S_i, q_{t+1} = S_j \mid \lambda') + a_{ij} \gamma = 0, \text{对 } j \text{ 求和}$$

$$\square \gamma = -P(O, q_t = S_i \mid \lambda')$$

$$\square a_{ij} = \frac{\sum_{t=1}^{T-1} P(O, q_t = S_i, q_{t+1} = S_j \mid \lambda')}{\sum_{t=1}^{T-1} P(O, q_t = S_i \mid \lambda')}$$

□ 第三项:  $\sum_Q \left( \sum_{t=1}^T \log b_{q_t}(o_t) \right) P(O, Q \mid \lambda') =$   
 $\sum_{j=1}^N \sum_{t=1}^T \log b_j(o_t) P(O, q_t = S_j \mid \lambda')$

□ 拉格朗日函数求导

□  $\frac{\partial}{\partial b_j(k)} \left( \sum_{j=1}^N \sum_{t=1}^T \log b_j(o_t) P(O, q_t = S_j \mid \lambda') + \gamma (\sum_{k=1}^M b_j(o_t = v_k) - 1) \right) = 0$

□  $\left( \sum_{t=1}^T \frac{1}{b_j(k)} P(O, q_t = S_j \mid \lambda') I(o_t = v_k) \right) + \gamma = 0$ , 其中  $I(o_t = v_k)$  表示当  
 $o_t = v_k$  取1, 否则取0.

□  $\sum_{t=1}^T P(O, q_t = S_j \mid \lambda') I(o_t = v_k) + b_j(k) \gamma = 0$  对  $k$  求和

□  $\gamma = - \sum_{t=1}^T P(O, q_t = S_j \mid \lambda')$

□  $b_j(k) = \frac{\sum_{t=1}^T P(O, q_t = S_j \mid \lambda') I(o_t = v_k)}{\sum_{t=1}^T P(O, q_t = S_j \mid \lambda')}$

$$\gamma_t(i) = P(q_t = S_i | O, \lambda) = \frac{P(O, q_t = S_i | \lambda)}{P(O | \lambda)}$$

$$\xi_t(i, j) = P(q_t = S_i, q_{t+1} = S_j | O, \lambda) = \frac{P(O, q_t = S_i, q_{t+1} = S_j | \lambda)}{P(O | \lambda)}$$

□ 使用  $\gamma_i(t), \xi_t(i, j)$  表示结果

$$\pi_i = \frac{P(O, q_1 = S_i | \lambda')}{P(O | \lambda')} = \gamma_i(1)$$

$$a_{ij} = \frac{\sum_{t=1}^{T-1} P(O, q_t = S_i, q_{t+1} = S_j | \lambda')}{\sum_{t=1}^{T-1} P(O, q_t = S_i | \lambda')} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

$$b_j(k) = \frac{\sum_{t=1}^T P(O, q_t = S_j | \lambda') I(o_t = v_k)}{\sum_{t=1}^T P(O, q_t = S_j | \lambda')} = \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)}$$

□ 和第一种情况比较

初始状态  $\pi_i$  的估计  $\hat{\pi}_i$  :  $\gamma_1(i)$

状态转移概率的估计  $\hat{a}_{ij} = \frac{\sum_{t=1 \dots T-1} \xi_t(i, j)}{\sum_{t=1, \dots, T-1} \gamma_t(i)}$

观测概率的估计  $\hat{b}_j(k) = \frac{\sum_{t=1, \dots, T, s.t. O_t=v_k} \gamma_t(j)}{\sum_{t=1, \dots, T} \gamma_t(j)}$



## □ 算法5: Baum-Welch算法

□ 输入：观测数据 $\mathbf{O}$ ，输出模型参数 $\lambda$

□ 初始化：  $n = 0, a_{ij}^{(0)}, b_j(k)^{(0)}, \pi_i^{(0)}$ ，模型  $\lambda^{(0)} = (A^{(0)}, B^{(0)}, \pi^{(0)})$

□ 递推，  $n = 1, 2, \dots, \dots$       $\pi_i^{(n+1)} = \gamma_i(1)$

$$a_{ij}^{(n+1)} = \frac{\sum_{t=1}^{T-1} \xi_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

$$b_j(k)^{(n+1)} = \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)}$$

□ 终止：得到模型：  $\lambda^{(n+1)} = (A^{(n+1)}, B^{(n+1)}, \pi^{(n+1)})$

# HMM 中的三个问题

问题	解决方法	本质	
识别问题	向前（前向）算法	递归计算	
学习问题	Baum-Welch 算法	EM算法	
解码问题	Viterbi算法	动态规划算法	

# HMM应用

问题	观测值	隐藏状态		
语音识别	语音信号	文字		
机器中英文翻译	中文	英文		
拼音输入法	拼音	中文候选文字		